# Plan de mejora de los detectores de régimen

*Qué queremos hacer, por qué, cómo vamos a reescribir el sistema y en qué orden · basado en PendientesOscar.md*

**En una frase.** Hemos descargado **106 series** de mercado y macro, pero los detectores solo leen **15**. El plan reescribe la entrada de los detectores para que aprovechen **todo** ese material sin «memorizar» las crisis, y añade una vara de medir estadística que diga qué detector es mejor *de verdad* y cuál solo ha tenido suerte.

## 1 · Qué es esto, explicado desde cero

- Un **régimen de mercado** es el «modo» en que está el mercado: **calma** o **crisis**. Un **detector** es un programa que cada día mira los datos y enciende un semáforo: verde o rojo.
- Lo examinamos como a un alumno: le damos la historia **día a día, sin dejarle ver el futuro** (*walk-forward* causal) y comprobamos si encendió el rojo en las crisis que ya conocemos.
- Hay **dos pistas**. **Pista A**: historia larga (1962–2026, 17 crisis evaluables) pero con pocas variables antiguas. **Pista B**: historia corta (2007–2026, 9 crisis) pero con muchas variables modernas (VIX, crédito, curva, divisas…).
- Hoy hay **12 detectores** de 7 familias: reglas sencillas, clustering, HMM, Markov-switching, GARCH, detección de cambios (CUSUM) y deep learning. Están **congelados**: no se tocan, son la referencia.

## 2 · El problema: tenemos muchos datos y usamos pocos

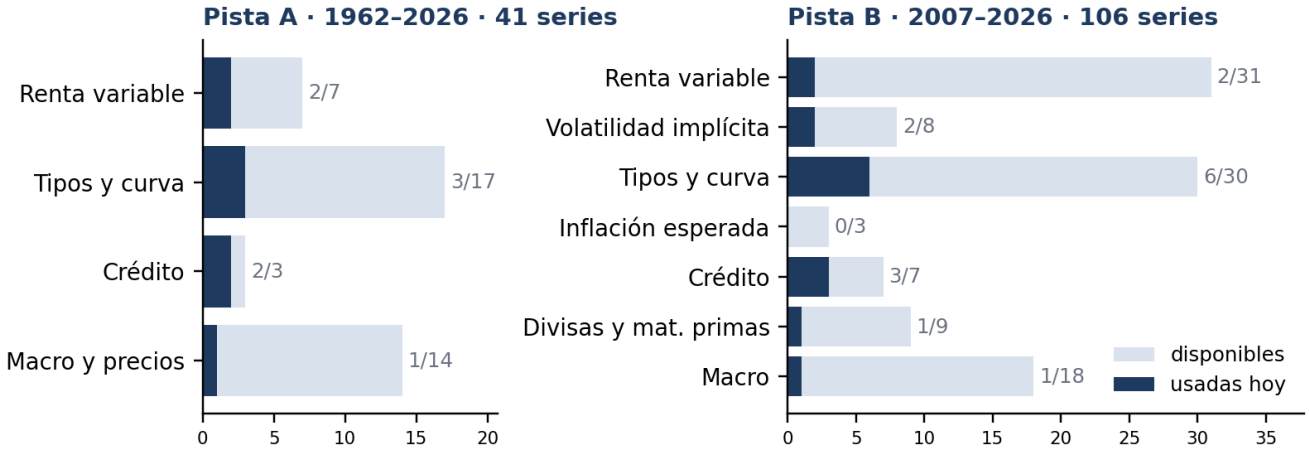
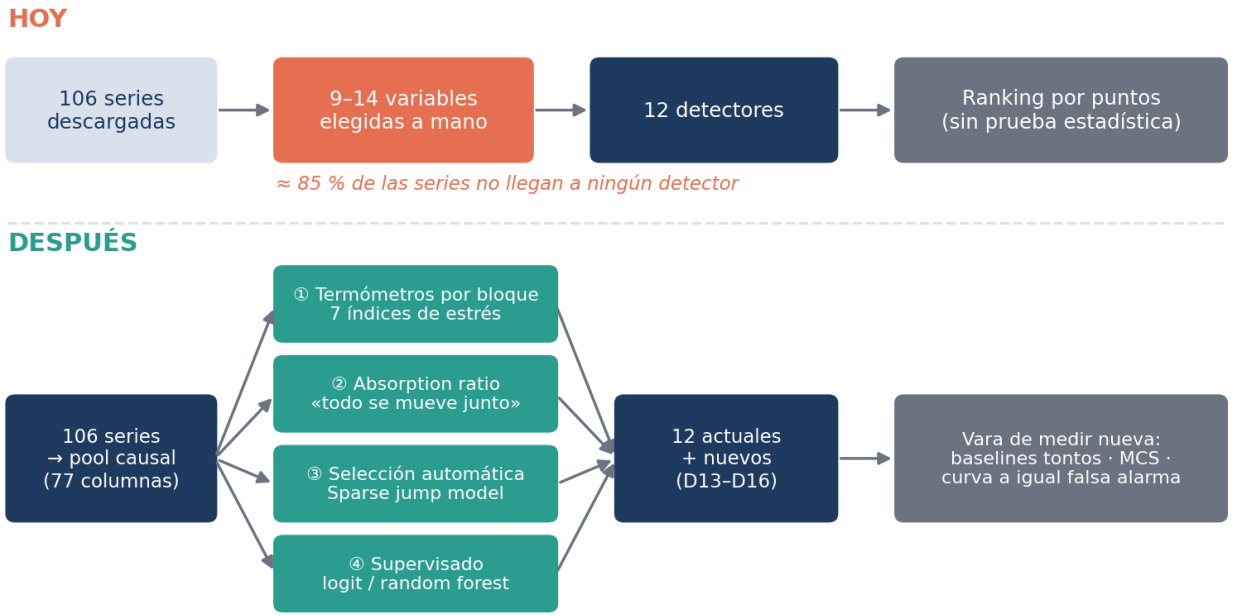



*Figura 1. Series del dataset congelado de cada pista (gris) frente a las que llegan a algún detector (azul). Pista A: 8 de 41 (20 %). Pista B: 15 de 106 (14 %). Recuento sobre configs/benchmark_spec.yaml y registry.py.*

- **¿Por qué usamos tan pocas?** Por dos buenas razones. (1) Las variables se eligieron **a mano y antes** de ver resultados, para no hacer trampa (*data snooping*). (2) Con solo 17 crisis, un modelo con muchas variables tiene tantos «botones» que **memoriza** las crisis en vez de aprender a reconocerlas.
- **¿Qué nos cuesta?** Hay familias enteras de datos que ningún detector mira: inflación esperada 0/3, macro 1/18, renta variable 2/31. El caso estrella es **2013** (*taper tantrum*): el EDA mostró que solo se ve en la **velocidad de los tipos de interés**, un bloque que casi no usamos.
- **La pregunta del plan:** ¿cómo meter **todas** las series sin multiplicar los botones del modelo?

## 3 · La idea central: reescribir los detectores alrededor del pool completo

El **pool** ya existe: las 106 series se transforman en **77 columnas** causales en la pista B (35 en la A), con z-scores calculados solo con el pasado y con el retraso de publicación de cada dato. Lo que falta es que los detectores lo **consuman**. Hay dos formas de usar mucho dato sin sobreajustar: **comprimirlo** en pocos números o dejar que el modelo **descarte** lo que no sirve (regularizar).




*Regla: más datos sí, más parámetros no → se comprime (①②) o se regulariza (③④). Con 17 crisis no hay para más.*

*Figura 2. Arriba, el flujo actual. Abajo, el flujo nuevo: cuatro rutas que leen el pool completo y desembocan en los mismos detectores y en una vara de medir más exigente.*

| Ruta | Qué hace, en cristiano | Qué datos usa | Pendiente |
|---|---|---|---|
| ① Termómetros por bloque | Agrupa las columnas en 7 bloques (renta variable, volatilidad, tipos, inflación, crédito, divisas y materias primas, macro) y resume cada bloque en **un solo número de estrés**: la dirección en la que sus series se mueven juntas (PCA causal). Los detectores actuales reciben 7 termómetros en vez de 9–14 variables escogidas a mano. | Las 77 / 35 columnas, todas | Nuevo: tapa el hueco del pool |
| ② Absorption ratio | Mide qué parte del movimiento total explican unos pocos factores. Si todo cae a la vez, el mercado es frágil: es la señal clásica de Kritzman, 2.ª mejor (dentro de muestra) en el benchmark de Hammond. | Columnas de rentabilidades del pool | B5 (prioridad 1) |
| ③ Selección automática | *Sparse jump model*: el propio modelo elige, dentro del walk-forward, qué columnas le sirven y pone peso cero al resto. | Las 77 / 35 columnas | B9 |
| ④ Supervisado | Logit y random forest que aprenden **solo de crisis ya pasadas**, con penalización para no memorizar. Hacen de techo de referencia y van en una categoría aparte del ranking. | Pool o termómetros + etiquetas de crisis | B7 |
| + Jump model «Shu» | Repite D09 con la receta del paper de Shu-Yu-Mulvey (medias exponenciales, desviación a la baja, penalización elegida fuera de muestra). Comprueba si D09 perdía por mala configuración. | Rentabilidades del S&P 500 | B6 |
| + Fusión online | Combina los detectores con pesos que se actualizan cada mes según su acierto pasado, en lugar de la regla fija actual (D02 alerta + D06 confirma). | Salidas de todos los detectores | C1 |

**Reglas que no se rompen.** (1) Más datos sí, más parámetros no. (2) Todo dato entra con su retraso real de publicación y todo cálculo usa solo el pasado. (3) Los 12 detectores y el ranking v2 quedan congelados: lo nuevo se añade **al lado** como D13 en adelante y ranking v3.

## 4 · Cómo sabremos si mejora: la vara de medir

Hoy ordenamos los detectores por puntos, pero **no sabemos si las diferencias son reales**. Con 17 crisis, un 0,61 y un 0,59 pueden ser el mismo nivel, igual que un 6,1 y un 5,9 en un examen de 17 preguntas.

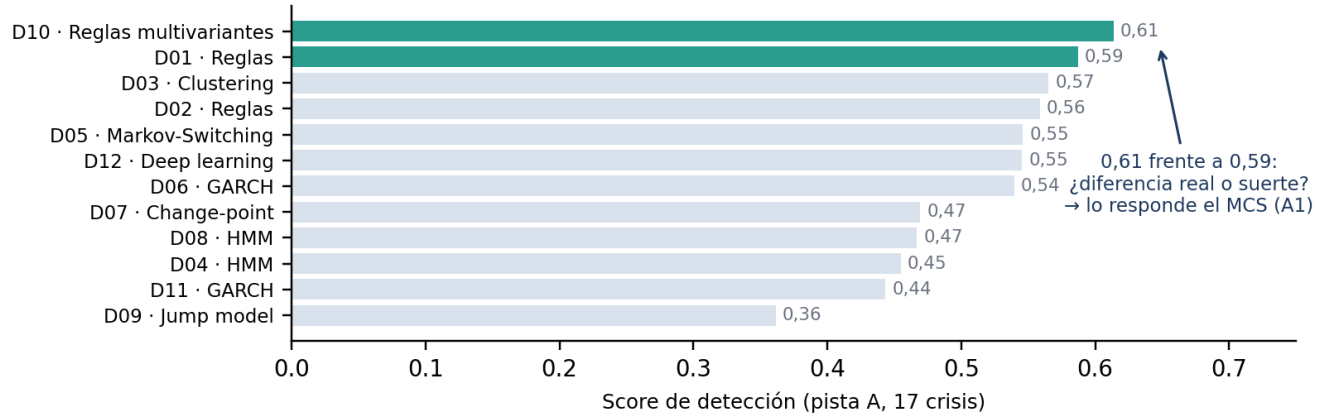


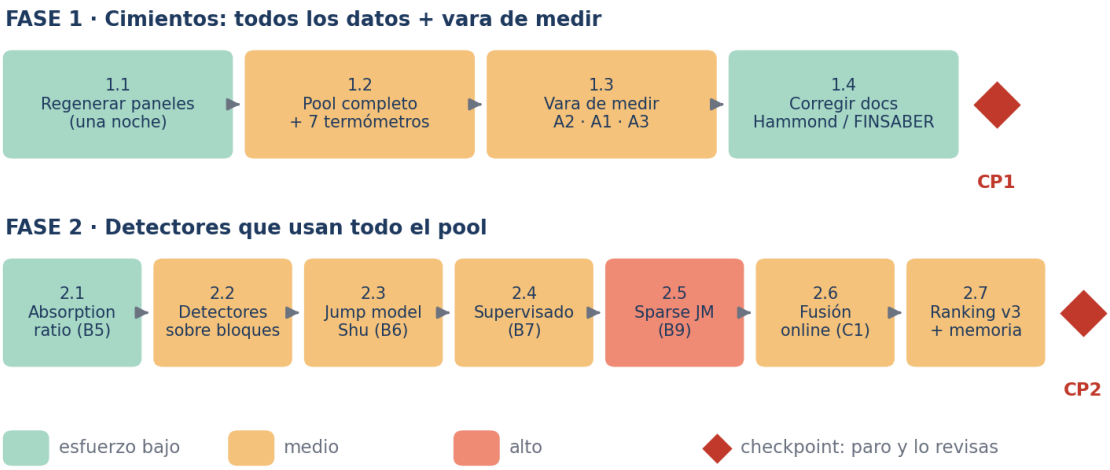

*Figura 3. Ranking actual de la pista A (results/benchmark/ranking_v2.csv). Ganan dos reglas sencillas, pero nada dice todavía si se distinguen del resto.*

- **Detectores tontos (A2).** Siempre calma, al azar y «volatilidad por encima del percentil 90». Si un detector no les gana, no aporta nada. Ya están casi todos en el código; falta el del percentil 90.
- **Model Confidence Set (A1).** En vez de un único ganador, da el **grupo de detectores indistinguibles del mejor**, remuestreando las crisis miles de veces. Es la frase que queremos poder escribir en la memoria.
- **Misma tasa de falsas alarmas (A3).** Ajustamos el umbral de cada detector para que todos den, por ejemplo, una falsa alarma al año, y entonces comparamos cuántas crisis detectan y con cuánto retraso. Es como poner a todos los corredores en la misma línea de salida.
- **Opcional (A4).** Un ranking «ajustado» en el que cada año se tunea solo con las crisis pasadas. La diferencia con el actual mide nuestro sesgo de optimismo. Es el punto más caro.

## 5 · Cómo vamos a reescribir el código

| Capa | Qué cambia | Dónde (src/regimenes/…) |
|---|---|---|
| Datos | Mapa columna → bloque y termómetros por PCA causal; opción de ampliar el pool con series que hoy se pierden al transformar. | features/bloques.py (nuevo) |
| Detectores | Absorption ratio (D13), jump model Shu (D14), logit y random forest (D15–D16), sparse jump model. Variantes declaradas «-bloques» de D03, D04, D08 y D10. | detectores/f1_reglas, f2_clustering, f8_supervisado (nueva familia), registry.py |
| Evaluación | Baseline del percentil 90, MCS, curva a igual tasa de falsas alarmas y ranking v3. | evaluacion/ranking.py, mcs.py y curvas.py (nuevos) |
| Fusión | Pesos online según el acierto pasado. | fusion/online.py (nuevo) |
| Notebooks | 21 pool y termómetros · 22 nuevos detectores · 23 significatividad · se actualiza 12. | notebooks/ |
| No se toca | Los 12 detectores, la interfaz RegimeDetector, el walk-forward y metrics_master_v2. | Congelado |

## 6 · El plan en dos fases




*Opcionales si sobra tiempo: A4 (ranking ajustado, el más caro) y B8 (BOCPD).*

*Figura 4. Orden de trabajo. En cada rombo paro y revisamos juntos antes de seguir.*

| Fase | Pasos | Qué te entrego en el checkpoint |
|---|---|---|
| 1 · Cimientos | 1.1 Regenerar los paneles diarios de los 12 detectores (unas 8 h de cálculo, una noche): sin ellos no hay MCS ni curva. 1.2 Termómetros por bloque, comprobando que suben en las crisis (y en 2013 en el bloque de tipos). 1.3 Vara de medir sobre los 12. 1.4 Corregir Hammond (no son «46 métodos clásicos y de ML» sino 22 propios + 24 baselines) y verificar cifras en los PDF. | Gráfica de los 7 termómetros, tabla «indistinguibles del mejor» por pista y curva detección-falsas alarmas. |
| 2 · Todo el pool | 2.1 Absorption ratio. 2.2 Detectores sobre termómetros. 2.3 Jump model Shu. 2.4 Supervisado. 2.5 Sparse jump model. 2.6 Fusión online. 2.7 Ranking v3 con MCS y curva otra vez, memoria del TFM y ADR. | Ranking final: ¿usar todo el pool mejora de verdad (MCS) o confirma que lo simple gana? |

## 7 · Decisiones que tienes que tomar

| # | Decisión | Opciones | Recomiendo |
|---|---|---|---|
| 1 | Rama de trabajo | Nueva desde main | feat/detectores-pool |
| 2 | Regenerar paneles | Las dos pistas esta noche / solo B (<1 h) | Las dos |
| 3 | Bloques del pool | Los 7 de la figura 1 / otra agrupación | Los 7 |
| 4 | Termómetro | 1.ª componente PCA / media de z-scores | PCA, con la media como control |
| 5 | ¿Ampliar el pool? | Mantener 77/35 columnas / añadir series que hoy se pierden | Mantener en Fase 1 |
| 6 | Pérdida del MCS | Acierto por crisis + días de falsa alarma / 1 − cobertura | La primera |
| 7 | Remuestreo del MCS | Por crisis / por bloques de días · α = 0,10 o 0,25 | Bloques de días, α = 0,10 |
| 8 | Falsas alarmas objetivo (A3) | 1 al año / 2 al año | 1 al año |
| 9 | Absorption ratio | Parámetros de Kritzman / fijar otros a priori | Kritzman |
| 10 | Penalización del jump Shu | Utilidad de estrategia / acierto en crisis | Utilidad (sin etiquetas) |
| 11 | Supervisado | Solo crisis pasadas / leave-one-crisis-out (Hammond) | Solo pasadas (causal) |
| 12 | Opcionales A4 y B8 | Hacer / trabajo futuro | Trabajo futuro |
| 13 | PDF de Hammond y FINSABER | ¿Dónde están? | Pásamelos |

**Glosario rápido. Walk-forward**: entrenar con el pasado y evaluar el día siguiente, avanzando en el tiempo. **Z-score**: cuántas desviaciones típicas se aleja un dato de su historia. **PCA**: técnica que resume muchas series en la dirección en la que se mueven juntas. **Sobreajuste**: memorizar el pasado en vez de aprender. **Pool**: todas las columnas del dataset congelado de cada pista.