

Detección de regímenes de mercado: un marco de evaluación causal y comparativo

Primera capa del TFM — banco de pruebas de 12 detectores

Oscar

Máster en Inteligencia Artificial aplicada a los Mercados Financieros (MIAX)

Junio de 2026

Resumen

Este informe sintetiza la primera capa de un TFM mayor sobre detección de regímenes de mercado. Su objeto **no** es proponer un detector concreto, sino construir un **marco de evaluación causal, comparable y honesto** con el que juzgar a muchos detectores bajo el mismo protocolo. Se implementan y evalúan **12 detectores** de **7 familias** (reglas, clustering, HMM, Markov-Switching, GARCH/RS-GARCH, change-point y redes) con un protocolo *walk-forward* out-of-sample sin *look-ahead*, sobre el S&P 500 y un universo multiactivo (1985–2026). El resultado central es que **no existe un detector dominante**: cuatro familias se reparten seis ejes de calidad. La cobertura de crisis sistémicas grandes la lideran el Markov-Switching de varianza (D5), el GARCH-t (D6) y una simple regla sobre el VIX (D1); la especificidad, la persistencia, la anticipación y el coste los domina el *change-point* CUSUM (D7); y el ajuste estadístico (BIC) lo gana el HMM t-Student de cuatro estados (D8). Además se documentan seis hallazgos metodológicos transversales —el corazón del trabajo— y se recomienda, de forma *consistente con* (no “confirmando”) la propuesta del TFM mayor, un núcleo HMM t-Student multi-estado complementado con un change-point rápido. El informe es autocontenido y declara con transparencia sus limitaciones: $n \approx 4$ crisis sin contraste de significancia, BIC in-sample, y lead/lag censurado por la ventana de búsqueda.

1. Resumen ejecutivo

Qué se hizo. Se diseñó un marco único de evaluación (`src/evaluation.py`) y una interfaz común de detector (`src/detector_base.py`) con etiquetas canónicas ($0 = \text{calma} \dots n-1 = \text{crisis}$). Cada uno de los 12 detectores se reentrena y predice en ventanas *walk-forward* expandidas, produciendo etiquetas *out-of-sample* (OOS) sin ver el futuro. Sobre esas etiquetas se calculan las mismas métricas para todos: cobertura de crisis, especificidad en ventanas-trampa, lead/lag, frecuencia de conmutación, persistencia y —donde el modelo lo permite— bondad de ajuste ($\log L/AIC/BIC$).

Qué se halló. (i) Ninguna familia gana en todo: hay un *mejor-para-qué*, no un mejor absoluto. (ii) Para cubrir crisis grandes y lentas basta con reaccionar a la volatilidad con suficiente histórico: el MS de varianza (D5, 0.98), el GARCH-t (D6, 0.97) y la regla VIX (D1, 0.92) empatan prácticamente en cobertura de GFC+COVID —primer aviso de parsimonia. (iii) El change-point CUSUM (D7) es el único con especificidad 1.00 en las dos trampas, la mayor persistencia (≈ 436 días) y el menor coste. (iv) El HMM t-Student de 4 estados (D8) ajusta mucho mejor que su gemelo gaussiano ($\Delta BIC \approx +10\,963$). (v) Los dos modelos más complejos (MS-GARCH y auto-encoder) *no* superan a los baselines: la parsimonia queda validada. (vi) El *taper tantrum* de 2013 es un punto ciego universal: ningún detector basado en volatilidad lo ve, porque fue un shock de tipos sin estrés sistémico de renta variable.

Qué se recomienda. Llevar a la siguiente capa un **núcleo HMM t-Student multi-estado** (D8), *consistente con* la propuesta original del TFM, emparejado con un **change-point rápido**

tipo D7 como sistema de alerta temprana / “segunda velocidad”, y conservar D1/D5/D6 como controles *baseline*. Se descartan como detectores operativos los exploratorios negativos D11 y D12.

2. Introducción y objetivo de la capa

2.1. De dónde viene este trabajo

Esta capa nace del detector de regímenes de una práctica previa: un **HMM gaussiano de 2 estados, ajustado in-sample y con *look-ahead***. Aquel modelo acertaba las crisis sistémicas grandes (Lehman 2008: 98.6 % de días en crisis; COVID 2020: 92.3 %) pero se perdía las correcciones rápidas (Taper Tantrum 2013: 10.9 %; sell-off del Q4 2018: 20.6 %). De su análisis crítico salieron ocho limitaciones que motivan este banco de pruebas: usar sólo 2 estados; ser ciego a crisis rápidas; etiquetar por umbral *post-hoc*; entrenar in-sample sin validación *walk-forward*; asumir emisiones gaussianas (que subestiman las colas); estandarizar con estadísticos de toda la muestra (otra fuga de futuro sutil); una inicialización degenerada; y no reportar incertidumbre (Viterbi “duro” en vez de probabilidades suaves).

2.2. Qué propone el TFM mayor

El TFM mayor define el sistema objetivo: un **HMM t-Student de 4 estados**, con selección de K por BIC y una lógica de “**dos velocidades**” que distingue la corrección rápida de la crisis sistémica lenta. La pregunta que esta capa debe responder con evidencia es: *¿la exploración de detectores respalda esa elección, o sugiere ajustarla?*

2.3. Qué es —y qué no es— esta capa

Esta capa **no es un detector concreto**. Es un **marco de evaluación causal, comparativo y honesto** que enfrenta 12 detectores de 7 familias bajo una sola interfaz y un protocolo OOS común. Su tesis central no es “cuál es el mejor detector” sino “**cuál es el mejor para qué**”: cada familia domina un eje distinto, y la comparación sólo es legítima si se hace **causal y con equidad de ventana**.

3. Datos y marco causal de evaluación

3.1. Datos

Se descarga un universo multiactivo sin imputar (cada serie arranca en su fecha real): S&P 500, VIX, MOVE, treasuries (TLT, IEF), crédito *high yield* (HYG), oro (GLD), dólar (DXY) y la pendiente de la curva ($\sim\text{TNX} - \sim\text{IRX}$). La ventana común sin huecos es **2007-04-11 → 2026-06-12** (gobernada por el inicio de HYG), de la que se derivan **15 *features* causales**. Varios detectores que sólo necesitan S&P 500 y/o VIX usan históricos más largos (desde 1985/1990/1993), lo que les permite evaluar la GFC de 2008 *out-of-sample*.

Dos hechos estilizados del análisis exploratorio gobiernan el diseño: las **colas pesadas** (curtosis en exceso de 25.6 en el S&P 500 y 39.6 en HYG; Figura 2), que motivan emisiones t-Student y GARCH; y la **subida de correlaciones en crisis** (Figura 3), que motiva los detectores multi-variantes de turbulencia. La verdad-terreno de eventos (ventanas de crisis y trampas, y los suelos de *drawdown*) se fija sobre la serie real del S&P 500 (Figura 1).




Figura 1: S&P 500 (escala log) y su *drawdown* desde 1985, con las ventanas de **crisis** (rojo) y de **trampa / falso positivo** (naranja) que definen el protocolo de evaluación. Estas ventanas son la verdad-terreno frente a la que se mide cobertura, especificidad y lead/lag.




Figura 2: Distribución de retornos diarios frente a la Normal (eje log). El exceso de curtosis (25.6 en el S&P 500, 39.6 en HYG) justifica colas pesadas y modelos t-Student/GARCH.




Figura 3: Matriz de correlación de retornos diarios. La estructura renta-fija/renta-variable justifica el universo multiactivo de los detectores de turbulencia y clustering.

3.2. El contrato de comparabilidad

Tres principios, en la línea metodológica del *machine learning* financiero causal [11], hacen que la comparación sea legítima:

Features causales.

Toda estandarización es un *z-score* expandido (en t sólo se usan estadísticos de datos $\leq t$). Nunca media/desviación de toda la muestra: eso era el *look-ahead* detectado en la tarea previa.

Walk-forward OOS.

Nada se juzga in-sample. El detector se reentrena en ventanas expandidas y predice el bloque

siguiente con parámetros congelados; cada fecha recibe la predicción causal del fold que la cubrió por primera vez.

Misma interfaz, mismas métricas.

Cada detector implementa `RegimeDetector` y se puntúa con `evaluation.py`. Las etiquetas se canonicalizan por criterio económico **vol-primario** (los estados se ordenan por su volatilidad; el retorno medio sólo desempata entre volúmenes próximos), y el orden se re-fija con los retornos del S&P 500 en cada fold.

Este último punto (la canonicalización económica robusta por fold) es lo que hace *comparables* entre sí a familias que ni siquiera operan sobre retornos (varianza, σ GARCH, change-point, distancia de Mahalanobis). Sin él, la mitad de los detectores habrían sido incomparables o se habrían invertido aleatoriamente.

Métricas. (a) *Cobertura de crisis*: % de días en “crisis” dentro de 2008/2011/2020/2022 (alto = sensible). (b) *Especificidad*: no disparar de forma sostenida en las trampas 2013/2018 (bajo = específico). (c) *Lead/lag*: días entre la señal sostenida y el suelo del *drawdown* (negativo = anticipa). (d) *Tasa de falsas alarmas* global. (e) *Conmutación / persistencia* (penaliza el *flickering*). (f) $\log L/AIC/BIC$ donde el modelo lo permite.

4. Los 12 detectores

Se cubren las 7 familias, de *baseline* a avanzado, más dos exploratorios cuyo resultado negativo es informativo (Tabla 1).

Cuadro 1: Mapa de los 12 detectores: familia, clase y ventana de evaluación OOS. La columna *vio 2008 OOS* es decisiva: sólo los seis de histórico largo evaluaron la GFC fuera de muestra.

ID	Detector	Familia	Clase	Vio 2008 OOS
D1	rule_vix_threshold	F1 reglas	baseline	sí
D2	rule_composite_riskoff	F1 reglas	baseline	no
D3	clustering_gmm_k3	F2 clustering	baseline	no
D4	hmm_gaussian_2s	F3 HMM	baseline (puente)	no
D5	markov_switching_var_2s	F4 Markov-Switching	avanzado	sí
D6	garch_t_vol	F5 GARCH	avanzado	sí
D7	changepoint_online	F6 change-point	avanzado	sí
D8	hmm_tstudent_4s	F3 HMM (avanzado)	avanzado	no
D9	jump_model	F2↔F3 jump model	avanzado	no
D10	turbulence_mahalanobis	F1 multivariante	avanzado	sí
D11	msgarch_regime	F5 MS-GARCH	<i>explor.-negativo</i>	sí
D12	deep_ae_regime	F7 redes	<i>explor.-negativo</i>	no

D1 – regla VIX. [1] Autómata de 2 estados sobre el nivel del VIX con histéresis y *dwell*. Base-line de “miedo” limpio y persistente; entre los mejores en cobertura sistémica de ventana larga.

D2 – regla compuesta. Voto VIX + crédito + curva + *drawdown*. Mejora a D1 en 2022 pero a costa de más ruido; complementa, no sustituye.

D3 – GMM clustering. [15, 17] Mezcla gaussiana $K=3$ sin dinámica temporal. Buena cobertura pero *flickering* severo: aísla cuánto aporta la dinámica temporal.

D4 – HMM gaussiano (puente). [16, 19] Réplica causal del detector previo. Sirve para medir el efecto del *look-ahead*; su supuesto gaussiano subestima las colas y motiva a D8.

D5 – Markov-Switching de varianza. [6, 8] Probabilidades filtradas causales. Ganador de cobertura sistémica en ventana larga; control interpretable, pero caro.

D6 – GARCH-t. [2, 4] GJR-GARCH(1,1)-t con umbral causal sobre σ . Capta 2018 que D4 no; sensor de volatilidad fuerte y barato.

D7 – change-point CUSUM. [14, 18] CUSUM de Page online robusto sobre la volatilidad. Domina cuatro ejes (especificidad, persistencia, lead/lag, coste); mejor candidato a “segunda velocidad”.

D8 – HMM t-Student 4 estados. Colas pesadas con ν por estado. Gana el eje BIC; núcleo recomendado, con matices (Sección 7).

D9 – jump model. [12] Modelo de saltos penalizados ($\lambda=50$). Anti-flickering rotundo, pero pierde cobertura de crisis lentas.

D10 – turbulencia de Mahalanobis. [9, 10] Distancia multivariante con covarianza expandida. Capta sistémicas pero no 2013 (no fue turbulencia conjunta).

D11 – MS-GARCH (*negativo*). [5] MS-GARCH-t de Haas-Mittnik-Paoletta. Degenera en *walk-forward*: el fold de la GFC colapsa a un régimen ($\text{cov_GFC} = 0\%$).

D12 – autoencoder (*negativo*). [7] AE $\rightarrow$ GMM frente a baseline PCA $\rightarrow$ GMM. El autoencoder empeora al PCA sin ganar cobertura: la no linealidad no aporta con pocos datos.

5. Resultados comparativos

5.1. Tabla maestra

La Tabla 2 resume el comportamiento global. La separación por ventana es obligatoria: las dos mitades no son directamente comparables en cobertura.

Cuadro 2: Tabla maestra resumida (valores *verbatim* de `results/metrics_master.csv`). *switching*: conmutaciones por día (bajo = persistente); *dur.*: duración media de régimen en días; *FA global*: tasa global de falsa alarma; BIC sólo en modelos generativos.

ID	Detector	Vent.	switching	dur. (d)	FA global	BIC
<i>Ventana larga (vio 2008 OOS)</i>						
D6	<code>garch_t_vol</code>	1993–2026	0.0141	70.15	0.845	26 627
D5	<code>markov_switching_var_2s</code>	1993–2026	0.0557	17.92	0.774	28 024
D7	<code>changepoint_online</code>	1993–2026	0.0022	435.68	0.867	—
D1	<code>rule_vix_threshold</code>	1998–2026	0.0132	75.20	0.697	—
D10	<code>turbulence_mahalanobis</code>	1998–2026	0.0873	11.44	0.815	—
D11	<code>msgarch_regime (neg.)</code>	1991–2026	0.0312	31.93	0.949	26 823
<i>Ventana corta (no vio 2008 OOS)</i>						
D3	<code>clustering_gmm_k3</code>	2015–2026	0.1261	7.91	0.494	63 016
D4	<code>hmm_gaussian_2s</code>	2012–2026	0.1004	9.93	0.731	35 379
D2	<code>rule_composite_riskoff</code>	2015–2026	0.0385	25.72	0.725	—
D8	<code>hmm_tstudent_4s</code>	2012–2026	0.0520	19.13	0.519	24 416
D9	<code>jump_model</code>	2015–2026	0.0053	176.60	0.624	—
D12	<code>deep_ae_regime (neg.)</code>	2015–2026	0.2873	3.48	0.603	—

5.2. Cobertura de crisis: estricta y estrés agregado

La cobertura “estricta” cuenta los días en el estado de crisis ($\text{state} = n-1$). Para comparar con justicia los detectores multi-estado con los binarios se define además el **estrés agregado**: en binarios coincide con la crisis; en multi-estado ($n \geq 3$) es la unión de los dos estados más severos (corrección + crisis). Las Tablas 3 y 4 reportan ambas.

Cuadro 3: Cobertura de crisis con definición **estricta** (proporción de días en crisis por ventana). *NaN* = ventana fuera del rango OOS del detector (no se penaliza lo que no se pudo ver).

ID	Detector	GFC 2008	EuroDeuda 2011	COVID 2020	Inflación 2022
<i>Ventana larga</i>					
D6	garch_t_vol	1.000	0.741	0.940	0.804
D5	markov_switching_var_2s	0.993	0.741	0.960	0.737
D7	changepoint_online	1.000	0.671	0.840	0.766
D1	rule_vix_threshold	0.938	0.635	0.900	0.349
D10	turbulence_mahalanobis	0.822	0.482	0.760	0.431
D11	msgarch_regime (<i>neg.</i>)	0.000	0.118	0.200	0.359
<i>Ventana corta</i> (GFC y EuroDeuda fuera de OOS)					
D3	clustering_gmm_k3	NaN	NaN	0.960	0.865
D4	hmm_gaussian_2s	NaN	NaN	0.960	0.861
D2	rule_composite_riskoff	NaN	NaN	0.840	0.538
D8	hmm_tstudent_4s	NaN	NaN	0.660	0.332
D9	jump_model	NaN	NaN	0.720	0.168
D12	deep_ae_regime (<i>neg.</i>)	NaN	NaN	0.540	0.101

Cuadro 4: Cobertura con **estrés agregado** (corrección + crisis) para los tres multi-estado; en los binarios coincide con la estricta. El criterio relajado eleva mucho la cobertura de crisis lentas de D8 y D12.

ID	Detector (<i>K</i>)	COVID 2020		Inflación 2022	
		estricta	estrés	estricta	estrés
D3	clustering_gmm_k3 (<i>K</i> =3)	0.960	0.960	0.865	0.865
D8	hmm_tstudent_4s (<i>K</i> =4)	0.660	0.960	0.332	0.904
D12	deep_ae_regime (<i>K</i> =3)	0.540	0.960	0.101	0.788

El estrés agregado tiene **dos caras**, y mostrar ambas es la lectura honesta (Figura 7): elevar a “corrección + crisis” sube la cobertura de crisis lentas, *pero también* la activación en las trampas. En D8 el sell-off de 2018 pasa de 0.034 a 0.814 y la tasa global de falsa alarma de 0.52 a 0.79; en D3, la trampa de 2018 salta de 0.000 a 0.729 (Tabla 5). No es una mejora gratuita, es un *trade-off*.

Cuadro 5: Especificidad en las ventanas-trampa (proporción de días “encendido”; bajo = mejor). Se muestran la versión estricta y la de estrés agregado. *NaN* = trampa fuera del OOS del detector.

ID	Detector	Taper 2013		Sell-off 2018	
		estricta	estrés	estricta	estrés
D7	changepoint_online	0.000	0.000	0.000	0.000
D1	rule_vix_threshold	0.000	0.000	0.063	0.063
D5	markov_switching_var_2s	0.038	0.038	0.810	0.810
D6	garch_t_vol	0.113	0.113	0.873	0.873
D10	turbulence_mahalanobis	0.123	0.123	0.302	0.302
D9	jump_model	NaN	NaN	0.000	0.000
D3	clustering_gmm_k3	NaN	NaN	0.000	0.729
D8	hmm_tstudent_4s	0.000	0.000	0.034	0.814
D12	deep_ae_regime (<i>neg.</i>)	NaN	NaN	0.153	0.186
D11	msgarch_regime (<i>neg.</i>)	0.000	0.000	0.937	0.937

5.3. Los planos de *trade-off*

Las Figuras 4 y 5 cruzan los ejes en lugar de apilar tablas. Para que la comparación sea justa entre ventanas largas y cortas, la **sensibilidad se mide en la ventana OOS común a los**

doce (COVID 2020); la cobertura de la GFC se ranquea sólo dentro del bloque de ventana larga.




Figura 4: Plano sensibilidad ↔ especificidad. Eje X: especificidad = 1 – media de falsa alarma en 2013/2018. El color/forma codifica el grupo de ventana; D11/D12 son exploratorio-negativos.




Figura 5: Plano persistencia (duración media, eje log) ↔ sensibilidad. D3/D12 *flickean*; D7 y las reglas son muy persistentes.




Figura 6: BIC de los modelos generativos (menor = mejor). **Aviso:** sólo es estrictamente comparable sobre las mismas *features* (D4 frente a D8). Gris = negativo.




Figura 7: Multi-estado: cobertura estricta frente a estrés agregado en COVID 2020 e Inflación 2022. Lectura honesta de los dos lados del *trade-off*.




Figura 8: Ranking por eje (1 = mejor; más oscuro = mejor rango). **Corrige el defecto** de la versión previa: la cobertura se separa por ventana —la GFC 2008 sólo rankea entre los seis detectores de ventana larga, COVID 2020 entre los doce— y las filas se agrupan por grupo de ventana. El lead/lag medio está censurado (ver Sección 8).




Figura 9: Lead/lag por evento (días de *trading*; negativo = la señal sostenida anticipa el suelo del *draw-down*). El asterisco y el borde discontinuo marcan los valores **censurados** en ± 252 días: la señal ya estaba activa al inicio de la ventana de búsqueda, de modo que no es anticipación genuina sino sesgo *always-on*. Filas separadas por grupo de ventana.

5.4. Reparto del podio

La Tabla 6 resume qué familia gana en qué eje. **Cuatro familias se reparten seis ejes; no existe detector dominante.**

Cuadro 6: Reparto del podio por eje. La cobertura sistémica se da separada por grupo de ventana (nunca mezclada).

Eje	Familia ganadora	Detalle
Cobertura sistémica (ventana larga)	F4 Markov-Switching	D5 0.98 > D6 0.97 $\approx$ D1/D7 0.92
Cobertura sistémica (ventana corta)	F2/F3 baseline	D3 0.96 = D4 0.96 > D2 0.84
Especificidad (trampas)	F6 change-point	D7 1.00 en ambas trampas
Persistencia / anti-flicker	F6 change-point	D7 436 d; switching 0.002
Lead/lag (sostenido)	F6 change-point	D7 anticipa temprano en todos los eventos
Ajuste BIC (in-sample)	F3 HMM t-Student	D8 24 416; Δ BIC +10 963 vs D4
Coste computacional	F6 / F1	D7 / D1 (bajo)

5.5. Scorecard e incertidumbre de cobertura

La Figura 10 condensa el reparto del podio en un *scorecard*: seis ejes normalizados a $[0, 1]$ por columna para los doce detectores. La lectura es inmediata —ningún detector es verde en todas las columnas: “mejor-para-qué” hecho imagen.




Figura 10: Scorecard “mejor-para-qué”: seis ejes normalizados por columna (verde = mejor en ese eje). Ningún detector domina todas las columnas; cada familia brilla en su eje.

Como respuesta directa al trabajo futuro B1 (Sección 8), se añade una cuantificación de incertidumbre *intra-evento*: para cada ventana de crisis se calcula un intervalo de confianza al 95 % de la cobertura mediante *bootstrap por bloques* (bloques de 5 días, que preservan la autocorrelación de los episodios). La Figura 11 lo muestra para COVID-2020, la única ventana OOS común a los doce detectores. Las bandas son anchas —coherente con $n \approx 4$ crisis— y dejan ver que

diferencias de pocos puntos de cobertura *no* son distinguibles, en línea con la cautela declarada en las limitaciones.




Figura 11: Cobertura de COVID-2020 con intervalo de confianza al 95 % por *bootstrap* de bloques. El intervalo es *intra-evento* (muestreo de días autocorrelados), no entre eventos: no sustituye a un contraste de significancia con $n \approx 4$ crisis.

6. Hallazgos metodológicos transversales

Son el verdadero producto de esta capa: lecciones sobre *cómo* evaluar regímenes de forma honesta, transferibles más allá de cualquier detector concreto.

(a) El *look-ahead* compraba suavidad, no acierto. Al reimplementar el HMM gaussiano de la tarea previa de forma causal (D4), la conmutación sube de 0.047 (in-sample) a 0.100 (causal) y el modelo sigue fallando 2013 (25 %) y 2018 (46 %). El acierto en crisis grandes nunca depende del *look-ahead*; lo que éste aportaba era **cosmética temporal** (persistencia falsa “prestada del futuro”), no capacidad de clasificación.

(b) El Viterbi por bloque era menos causal y menos estable que el filtrado forward. Al sustituir el Viterbi intra-bloque por **filtrado forward** en D4/D8, la conmutación bajó de 0.124 a 0.100 y la duración media subió de 8.1 a 9.9 días. Contra la intuición, el cambio mejoró la estabilidad: el Viterbi reiniciaba la decodificación en cada frontera de bloque (21 días), inyectando conmutación artificial; el filtro forward con *burn-in* es continuo —más causal y más persistente. El “óptimo” offline introduce un artefacto de frontera que el filtrado causal evita.

(c) La t-Student está bien especificada; el gaussiano no. Con las mismas 7 *features*, el HMM t-Student de 4 estados (D8) bate al gaussiano de 2 estados (D4) por $\Delta\text{BIC} \approx +10\,963$ (Tabla 7). Más aún, D8 estima los grados de libertad ν **decrecientes por estado** [10.2, 7.6, 4.2, 2.4]: la calma es casi gaussiana y la crisis tiene las colas más pesadas, exactamente la estructura que predice la teoría de los hechos estilizados [3, 13]. La t-Student no es un adorno: es la corrección distribucional que la curtosis 25–40 de los datos exige.

Cuadro 7: Bondad de ajuste de los modelos generativos. El BIC sólo es comparable sobre las mismas *features*: el contraste limpio es D4 frente a D8 (ambos HMM, mismo conjunto de 7 *features* puente).

ID	Detector	logL	AIC	BIC
D8	hmm_tstudent_4s	−11 536.3	23 390.7	24 415.9
D6	garch_t_vol	−13 285.6	26 583.1	26 626.6
D11	msgarch_regime (<i>neg.</i>)	−13 365.5	26 750.9	26 823.3
D5	markov_switching_var_2s	−13 984.2	27 980.3	28 023.8
D4	hmm_gaussian_2s	−17 381.4	34 908.7	35 379.4
D3	clustering_gmm_k3	−29 789.0	60 392.0	63 016.2
$\Delta\text{BIC (D4} - \text{D8)} = 35\,379.4 - 24\,415.9 = \mathbf{10\,963.5}$ (evidencia “muy fuerte”)				

(d) **El taper tantrum de 2013 es un punto ciego universal.** Seis detectores independientes de familias distintas que sí tuvieron 2013 en su OOS coinciden en *no* verlo (activación entre 0 y $\sim 12\%$): D1 reglas (0.00), D5 MS-VAR (0.038), D6 GARCH (0.113), D7 change-point (0.00), D8 HMM-t (0.00) y D10 turbulencia (0.123). El hallazgo **no** es “2013 es ruido reclasificable”; es que **ninguna definición de crisis basada en volatilidad o correlación de renta variable captura 2013**, porque el *taper* fue un shock de *tipos* sin estrés sistémico de renta variable. Que seis detectores converjan es *evidencia robusta*, no un fallo común: **la taxonomía de régimen importa**. Capturar 2013 exigiría ampliar la taxonomía de *features* (curva de tipos, MOVE) o de regímenes, no afinar un umbral; por eso 2013 se mantiene como ventana-trampa para medir especificidad.

(e) **La complejidad no se paga: parsimonia validada.** Los dos modelos más complejos son resultados negativos explícitos. El MS-GARCH-t (D11) *degenera* en *walk-forward*: el fold de la GFC colapsa a un único régimen, con cobertura de 2008 del 0% y tasa de falsa alarma del 0.95. El autoencoder (D12) *empeora* a su baseline lineal PCA $\rightarrow$ GMM (conmutación 0.287 frente a 0.091, falsa alarma 0.60 frente a 0.14) sin ganar cobertura. Con ~ 4 crisis en la muestra, la riqueza paramétrica no se identifica: a veces es neutra (D12), a veces destructiva (D11). Los baselines cubren los huecos que los complejos dejan.

(f) **Dos arreglos imprescindibles del marco de evaluación.** (i) **Severidad vol-primaria:** con $K=2$, ordenar los estados por $z(\text{std}) - z(\text{media})$ dejaba que el signo ruidoso de una diferencia de medias casi nula invirtiera crisis $\leftrightarrow$ calma en detectores que separan sólo en varianza (σ GARCH, turbulencia). La solución fue ordenar por banda de volatilidad (ancho 15% de la vol media) y desempatar por retorno sólo entre volúmenes próximos. (ii) **Etiquetado económico por fold:** re-fijar el orden 0 = calma $\dots$ $n-1$ = crisis con los retornos de *cada* fold. Sin estos dos arreglos, la mitad de los detectores habrían sido incomparables.

7. Recomendación para la siguiente capa

La propuesta del TFM mayor es un HMM t-Student de 4 estados con lógica de “dos velocidades”. **La evidencia de esta capa es consistente con ese núcleo y no lo contradice; sugiere complementarlo.** Se evita deliberadamente el verbo “confirma”: el respaldo a D8 descansa en un eje **in-sample** (BIC) y en una métrica **favorable por construcción** a $K \geq 3$ (el estrés agregado), *no* en cobertura OOS estricta, donde D8 es modesto.

1. **Núcleo HMM t-Student multi-estado (D8), reforzado por dos vías —cada una con su asterisco.**

- *Por BIC (in-sample)*: gana el eje de ajuste con holgura ($\Delta\text{BIC} \approx +10\,963$ sobre D4 con las mismas *features*). Pero el BIC es bondad de ajuste in-sample, no capacidad predictiva OOS.
 - *Por la lógica corrección↔crisis*: con estrés agregado, D8 iguala a los binarios (COVID $0.66 \rightarrow 0.96$; Inflación $0.33 \rightarrow 0.90$), lo que da sentido al cuarto estado y a la “segunda velocidad”. Pero el estrés agregado favorece por construcción a los multi-estado, la cobertura OOS estricta es modesta (COVID 0.66) y D8 nunca evaluó 2008 OOS. Es un argumento de *plausibilidad estructural*, no de superioridad OOS demostrada.
2. **Complementar con un change-point rápido (D7)** como segunda velocidad / alerta temprana: domina especificidad, persistencia, lead/lag y coste. Donde el HMM-t da la *taxonomía* (qué tipo de régimen), el change-point da la *reactividad* (cuándo cambia el nivel).
 3. **Conservar baselines de control**: D1 (regla VIX) y D5/D6 (MS-VAR / GARCH-t), con la mejor cobertura sistémica en ventana larga. Si un modelo complejo no bate a D1 en cobertura de GFC+COVID, no se justifica su coste.
 4. **Descartar D11 y D12** como detectores operativos: validan la parsimonia, no la aportan.

En síntesis: la exploración *no obliga* a cambiar la propuesta, pero la matiza. El cuarto estado tiene sentido (es la “corrección” que separa de la “crisis”) y la t-Student es necesaria, pero la validación definitiva del núcleo deberá hacerse con cobertura OOS estricta sobre más crisis y, a ser posible, con la GFC dentro de la muestra de prueba.

8. Limitaciones y trabajo futuro

La honestidad de este marco exige declarar sus límites:

Significancia con $n \approx 4$ crisis.

Toda la comparación descansa en cuatro crisis sistémicas (2008, 2011, 2020, 2022) y dos ventanas-trampa (2013, 2018). Se añaden **intervalos de confianza intra-evento** de la cobertura por *bootstrap* de bloques (Figura 11), pero **sigue sin haber contraste de significancia entre eventos**; diferencias de pocos puntos entre detectores *no* son estadísticamente distinguibles. El podio es evidencia cualitativa direccional, no una ordenación con respaldo inferencial. Es una limitación asumida del diseño (las crisis son raras por definición), no un descuido.

BIC in-sample.

Las métricas de comportamiento (cobertura, falsa alarma, lead/lag, persistencia) son OOS sin *look-ahead*; pero logL/AIC/BIC son **in-sample por definición**. El eje de BIC mide especificación, no capacidad predictiva fuera de muestra, y así se interpreta.

Lead/lag censurado.

El lead/lag se busca en los 252 días previos al suelo; un valor de -252 **no** significa “252 días exactos de anticipación”, sino que la señal ya estaba activa al inicio de la ventana —el lead real es ≥ 252 y queda sin medir (censura por la derecha). D7 toca ese tope en 3 de sus 4 eventos, así que su anticipación es un límite inferior (Figura 9); su virtud es *cualitativa* (cruza pronto y se mantiene), no una cifra precisa de días.

Equidad de ventana.

La GFC 2008 cae cerca del inicio de datos para las ventanas cortas: D8 nunca la evaluó OOS y su validación sistémica se apoya en COVID 2020. Por el mismo motivo, 2013 es N/A (fuera de OOS) para los detectores de ventana corta y no cuenta ni a favor ni en contra.

Trabajo futuro declarado. (B1) **Bootstrap por bloques** (*stationary/circular block bootstrap*) sobre las series OOS —*parcialmente abordado*: ya se proveen bandas de confianza de la cobertura por bloques (Figura 11); queda extenderlo a falsa alarma y conmutación, y a contrastes pareados entre detectores respetando la autocorrelación. (B2) **Análisis de sensibilidad de hiperparámetros** del protocolo *walk-forward* (`train_size`, `step`) y del etiquetado económico (`VOL_CLOSE_FRAC`), para comprobar que el reparto del podio es robusto y no un artefacto de la configuración elegida.

Nota de reproducibilidad

Todos los números de este informe provienen *verbatim* de un único master canónico, `results/metrics_master.csv` (43 columnas: comportamiento, ajuste, silueta e intervalos de cobertura), reconstruible con `_rebuild_master.py`. Las figuras `pdf_*.png` y `synth_*.png` (scorecard e IC de cobertura) se regeneran de forma determinista desde ese mismo CSV con los scripts de `scripts/figs_pdf/`; las `eda_*.png` provienen del análisis exploratorio. Las métricas de comportamiento y de ajuste son idénticas a la versión previa: esta revisión solo **añade** dos métricas —silueta de regímenes e intervalos de cobertura por *bootstrap*— sin re-tunear ningún detector ni alterar ninguna cifra anterior.

Referencias

- [1] Nicholas Bloom. The impact of uncertainty shocks. *Econometrica*, 77(3):623–685, 2009.
- [2] Tim Bollerslev. Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3):307–327, 1986.
- [3] Jan Bulla. Hidden markov models with t components. increased persistence and other aspects. *Quantitative Finance*, 11(3):459–475, 2011.
- [4] Lawrence R. Glosten, Ravi Jagannathan, and David E. Runkle. On the relation between the expected value and the volatility of the nominal excess return on stocks. *The Journal of Finance*, 48(5):1779–1801, 1993.
- [5] Markus Haas, Stefan Mittnik, and Marc S. Paoletta. A new approach to markov-switching garch models. *Journal of Financial Econometrics*, 2(4):493–530, 2004.
- [6] James D. Hamilton. A new approach to the economic analysis of nonstationary time series and the business cycle. *Econometrica*, 57(2):357–384, 1989.
- [7] Geoffrey E. Hinton and Ruslan R. Salakhutdinov. Reducing the dimensionality of data with neural networks. *Science*, 313(5786):504–507, 2006.
- [8] Chang-Jin Kim. Dynamic linear models with Markov-switching. *Journal of Econometrics*, 60(1-2):1–22, 1994. Filtro y suavizador de Kim; generaliza el MS al espacio de estados.
- [9] Mark Kritzman and Yuanzhen Li. Skulls, financial turbulence, and risk management. *Financial Analysts Journal*, 66(5):30–41, 2010.
- [10] Mark Kritzman, Sebastien Page, and David Turkington. Regime shifts: Implications for dynamic strategies. *Financial Analysts Journal*, 68(3):22–39, 2012.
- [11] Marcos López de Prado. *Advances in Financial Machine Learning*. Wiley, 2018.
- [12] Peter Nystrup, Erik Lindström, and Henrik Madsen. Learning hidden markov models with persistent states by penalizing jumps. *Expert Systems with Applications*, 150:113307, 2020.

- [13] Peter Nystrup, Henrik Madsen, and Erik Lindström. Stylised facts of financial time series and hidden markov models in continuous time. *Quantitative Finance*, 15(9):1531–1541, 2015.
- [14] E. S. Page. Continuous inspection schemes. *Biometrika*, 41(1/2):100–115, 1954. Artículo seminal del CUSUM (deteccion secuencial online).
- [15] Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, et al. Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [16] Lawrence R. Rabiner. A tutorial on hidden markov models and selected applications in speech recognition. *Proceedings of the IEEE*, 77(2):257–286, 1989.
- [17] Gideon Schwarz. Estimating the dimension of a model. *The Annals of Statistics*, 6(2):461–464, 1978.
- [18] Charles Truong, Laurent Oudre, and Nicolas Vayatis. Selective review of offline change point detection methods. *Signal Processing*, 167:107299, 2020. Survey de CPD offline (coste, busqueda, restriccion); base de la libreria ruptures.
- [19] Andrew J. Viterbi. Error bounds for convolutional codes and an asymptotically optimum decoding algorithm. *IEEE Transactions on Information Theory*, 13(2):260–269, 1967.